


SMART INSECT IDENTIFIER & AI INSIGHTS

disusun untuk memenuhi
tugas Praktikum Pembelajaran Mesin

Oleh:

ARIFA MUTHMAINNAH
(2308107010012)



PROGRAM STUDI S1 INFORMATIKA
FAKULTAS MATEMATIKA DAN ILMU PENGETAHUAN ALAM
UNIVERSITAS SYIAH KUALA
DARUSSALAM, BANDA ACEH
2026

DAFTAR ISI

DAFTAR ISI.....	2
BAB I	
PENDAHULUAN.....	3
1.1 Latar Belakang.....	3
1.2 Rumusan Masalah.....	3
1.3 Tujuan.....	3
1.4 Manfaat.....	4
BAB II	
TINJAUAN PUSTAKA.....	5
2.1 Machine Learning.....	5
2.2 Deep Learning.....	5
2.3 Convolutional Neural Network (CNN).....	5
2.4 EfficientNetB0.....	5
2.5 Large Language Model (LLM).....	5
2.6 Gemini AI.....	5
2.7 FastAPI.....	5
2.8 Next.js.....	6
BAB III	
METODOLOGI.....	7
3.1 Gambaran Umum Sistem.....	7
3.2 Dataset.....	8
3.3 Data Cleaning dan Preprocessing.....	11
3.3.1 Pembersihan Gambar Rusak (Data Cleaning).....	12
3.3.2 Resize Image.....	13
3.3.3 Normalisasi Data.....	13
3.3.4 Data Augmentation.....	13
3.3.5 Label Encoding.....	14
3.4 Exploratory Data Analysis (EDA).....	15
3.4.1 Distribusi Jumlah Data per Kelas.....	15
3.5 Pelatihan Model.....	17
3.5.1 Pembangunan Arsitektur Model.....	17
3.5.2 Konfigurasi Pelatihan.....	18
3.5.3 Callback Training.....	19
3.5.4 Training Tahap Pertama.....	19
3.5.5 Kendala Pelatihan.....	20
3.6 Fine Tuning Model.....	20
3.6.1 Proses Fine Tuning.....	20
3.6.2 Training Fine Tuning.....	21
3.7 Evaluasi dan Export Model.....	22
3.7.1 Evaluasi Model.....	22
3.7.2 Classification Report.....	23
3.7.3 Confusion Matrix.....	24

3.7.4 Export Model.....	25
Setelah evaluasi selesai, model terbaik diekspor ke dalam beberapa file yang digunakan pada tahap deployment. File yang disimpan meliputi:.....	25
BAB IV	
IMPLEMENTASI DAN HASIL SISTEM.....	26
4.1 Implementasi Backend.....	26
4.1.1 ML Service.....	26
ML Service bertanggung jawab untuk melakukan proses klasifikasi gambar serangga menggunakan model EfficientNetB0 yang telah dilatih. Proses yang dilakukan oleh ML Service meliputi:.....	26
Gemini diintegrasikan menggunakan Google Gemini 2.5 Flash Lite API. Gemini Service memungkinkan sistem tidak hanya melakukan identifikasi serangga, tetapi juga memberikan wawasan tambahan yang lebih informatif kepada pengguna.....	28
4.1.3 Endpoint API.....	28
Backend menyediakan endpoint utama:.....	28
POST /predict.....	28
Endpoint tersebut menerima file gambar yang dikirimkan dari frontend dan mengembalikan hasil klasifikasi beserta informasi AI.....	28
4.1.3 Fallback Mechanism.....	29
Sistem menerapkan mekanisme fallback apabila layanan Gemini mengalami kegagalan akibat rate limit atau error dari server. Jika Gemini tidak dapat memberikan respons, backend tetap mengembalikan:.....	29
• Nama serangga hasil prediksi.....	29
• Confidence score.....	29
Dengan demikian, proses identifikasi tetap dapat dilakukan walaupun layanan AI sedang tidak tersedia.....	29
4.2 Implementasi Frontend.....	29
4.2.1 Halaman Utama.....	29
Halaman utama menyediakan fitur upload gambar dan informasi singkat mengenai teknologi yang digunakan. Komponen utama pada halaman terdiri dari:.....	29
Informasi AI ditampilkan menggunakan React Markdown sehingga format heading dan list dapat ditampilkan dengan lebih rapi. Sistem menampilkan hasil klasifikasi beserta informasi tambahan yang dihasilkan oleh Gemini sehingga pengguna memperoleh informasi yang lebih lengkap mengenai serangga yang diidentifikasi.....	31
4.3 Pengujian Sistem.....	31
4.4 Pengujian Sistem.....	32
BAB V	
PENUTUP.....	34
5.1 Kesimpulan.....	34
5.1 Saran.....	34

BAB I

PENDAHULUAN

1.1 Latar Belakang

Identifikasi spesies serangga merupakan salah satu permasalahan yang sering dijumpai dalam bidang biologi, pertanian, dan konservasi lingkungan. Proses identifikasi secara manual membutuhkan pengetahuan khusus dan waktu yang tidak sedikit. Seiring berkembangnya teknologi kecerdasan buatan, proses identifikasi objek dapat dilakukan secara otomatis menggunakan model Deep Learning.

Pada proyek ini dikembangkan aplikasi Smart Insect Identifier yang memanfaatkan model EfficientNetB0 untuk melakukan klasifikasi gambar serangga. Selain menghasilkan prediksi spesies, sistem juga terintegrasi dengan Gemini AI untuk memberikan informasi tambahan berupa habitat, karakteristik, peran ekologis, dan fakta menarik mengenai serangga yang terdeteksi.

Dengan adanya sistem ini, pengguna dapat memperoleh informasi secara cepat hanya dengan mengunggah gambar serangga yang ingin dikenali.

1.2 Rumusan Masalah

Berdasarkan latar belakang yang telah diuraikan, maka rumusan masalah dalam proyek ini adalah sebagai berikut:

1. Bagaimana membangun model Deep Learning untuk mengidentifikasi serangga dari gambar?
2. Bagaimana mengintegrasikan Gemini AI untuk menghasilkan informasi tambahan mengenai serangga?
3. Bagaimana membangun aplikasi berbasis web yang mampu menampilkan hasil identifikasi secara interaktif?

1.3 Tujuan

Tujuan dari tugas ini adalah sebagai berikut:

1. Membangun model klasifikasi serangga berbasis Deep Learning.
2. Mengintegrasikan Gemini AI sebagai penyedia informasi tambahan.

3. Mengembangkan aplikasi web yang mudah digunakan untuk identifikasi serangga.

1.4 Manfaat

Tujuan dari tugas ini adalah sebagai berikut:

1. Membantu proses identifikasi serangga secara otomatis.
2. Menyediakan informasi edukatif mengenai serangga.
3. Menjadi implementasi nyata penerapan Machine Learning dan Large Language Model.

BAB II

TINJAUAN PUSTAKA

2.1 Machine Learning

Machine Learning merupakan cabang kecerdasan buatan yang memungkinkan sistem mempelajari pola dari data dan membuat prediksi tanpa diprogram secara eksplisit.

2.2 Deep Learning

Deep Learning merupakan bagian dari Machine Learning yang menggunakan jaringan saraf tiruan dengan banyak lapisan untuk mempelajari representasi data yang kompleks.

2.3 Convolutional Neural Network (CNN)

CNN merupakan arsitektur Deep Learning yang umum digunakan pada pengolahan citra. CNN mampu mengekstraksi fitur visual secara otomatis dari gambar.

2.4 EfficientNetB0

EfficientNetB0 merupakan model CNN yang menggunakan metode compound scaling sehingga mampu memberikan performa tinggi dengan jumlah parameter yang relatif sedikit. Keunggulan EfficientNetB0:

- Akurasi tinggi
- Parameter lebih efisien
- Cocok untuk transfer learning

2.5 Large Language Model (LLM)

Large Language Model merupakan model bahasa berbasis Transformer yang mampu memahami dan menghasilkan teks berdasarkan konteks yang diberikan.

2.6 Gemini AI

Gemini merupakan model AI generatif dari Google yang dapat digunakan untuk menghasilkan informasi, analisis, dan penjelasan berdasarkan prompt yang diberikan.

2.7 FastAPI

FastAPI adalah framework Python yang digunakan untuk membangun REST API dengan performa tinggi.

2.8 Next.js


Next.js merupakan framework React yang digunakan untuk membangun antarmuka web modern dengan performa yang baik.

BAB III

METODOLOGI

3.1 Gambaran Umum Sistem

Sistem terdiri dari dua bagian utama yaitu Backend dan Frontend. Frontend digunakan untuk menerima gambar dari pengguna dan menampilkan hasil identifikasi. Backend bertugas melakukan prediksi menggunakan model EfficientNetB0 serta meminta informasi tambahan kepada Gemini AI.



Gambar 3.1 Arsitektur Sistem

Gambar menunjukkan alur kerja sistem dimulai dari pengguna mengunggah gambar serangga melalui antarmuka web. Gambar kemudian dikirim ke backend FastAPI untuk

diproses oleh model EfficientNetB0. Hasil prediksi selanjutnya dikirim ke Gemini AI untuk menghasilkan informasi tambahan yang kemudian ditampilkan kembali pada frontend.

3.2 Dataset

Dataset yang digunakan berasal dari Kaggle, yakni <https://www.kaggle.com/datasets/baxtiyorbotiraliyev/insects>. Dataset ini berisi gambar berbagai spesies serangga. Jumlah kelas yang digunakan dalam proyek ini adalah 118 kelas serangga, yaitu:

- adristyrannus
- aleurocanthus spiniferus
- alfalfa plant bug
- alfalfa seed chalcid
- alfalfa weevil
- ampelophaga
- ant
- aphids
- apolygus lucorum
- armyworm
- asiatic rice borer
- bactrocera tsuneonis
- bee
- beet fly
- beetle
- black cutworm
- blister beetle
- bollworm
- brevipoalpus lewisi McGregor
- brown plant hopper
- butterfly
- catterpillar
- cerodonta denticornis
- ceroplastes rubens
- chayon

- *chlumetia transversa*
- *chrysomphalus aonidum*
- *cicadella viridis*
- cicadellidae
- corn borer
- *dacus dorsalis*(Hendel)
- *dasineura* sp
- *deporaus marginatus* Pascoe
- dragonfly
- earthworm
- earwig
- *erythroneura apicalis*
- fall armyworm
- flax budworm
- flea beetle
- fly
- grain spreader thrips
- grasshopper
- grub
- *icerya purchasi* Maskell
- kolorado
- ladybug
- large cutworm
- *lawana imitata* Melichar
- leaf beetle
- legume blister beetle
- limacodidae
- locustoidea
- longlegged spider mite
- *lycorma delicatula*
- *lytta polita*
- mango flat beak leafhopper
- meadow moth

- miridae
- mites
- mole cricket
- mosquito
- moth
- nipaecoccus vastalor
- odontothrips loti
- oides decempunctata
- paddy stem maggot
- panonchus citri McGregor
- papilio xuthus
- parathrene regalis
- parlatoria zizyphus Lucas
- peach borer
- penthaleus major
- phyllocnistis citrella Stainton
- phyllocoptes oleivorus ashmead
- pieris canidia
- polyphagotars onemus latus
- potosiabre vitarsis
- prodenia litura
- pseudococcus comstocki Kuwana
- red spider
- rhytidodera bowrinii white
- rice Stemfly
- rice gall midge
- rice leaf caterpillar
- rice leaf roller
- rice leafhopper
- rice shell pest
- rice water weevil
- salurnis marginella Guerr
- sawfly

- scirtothrips dorsalis Hood
- sericaorient alismots chulsky
- slug
- small brown plant hopper
- snail
- spider
- stem_borer
- sternochetus frigidus
- tarnished plant bug
- therioaphis maculata Buckton
- thrips
- toxoptera aurantii
- toxoptera citricidus
- trialeurodes vaporariorum
- unaspis yanonensis
- viteus vitifoliae
- wasp
- weevil
- wheat blossom midge
- wheat phloeothrips
- wheat sawfly
- white backed plant hopper
- white margined moth
- wire worm
- xylotrachus
- yellow cutworm
- yellow rice borer

3.3 Data Cleaning dan Preprocessing

Sebelum dilakukan proses pelatihan model, dataset terlebih dahulu melalui tahap pembersihan data (data cleaning) dan preprocessing. Tahap ini bertujuan untuk memastikan seluruh data yang digunakan memiliki kualitas yang baik sehingga proses pelatihan dapat berjalan dengan stabil dan menghasilkan performa model yang optimal.

Data cleaning dilakukan untuk menghilangkan gambar yang rusak atau tidak dapat dibaca oleh sistem. Setelah itu dilakukan beberapa tahapan preprocessing seperti resize image, normalisasi data, augmentasi data, dan label encoding agar data sesuai dengan kebutuhan model EfficientNetB0.


3.3.1 Pembersihan Gambar Rusak (Data Cleaning)

Pada dataset citra sering ditemukan beberapa file gambar yang mengalami kerusakan (corrupt image), format yang tidak valid, atau tidak dapat dibaca oleh library pengolahan citra. Jika gambar-gambar tersebut tetap digunakan, proses training berpotensi mengalami error dan menyebabkan pelatihan model gagal dilakukan.

Oleh karena itu dilakukan proses pemeriksaan terhadap seluruh gambar pada folder training, validation, dan testing menggunakan library Pillow (PIL). Setiap gambar dibuka, dikonversi ke format RGB, kemudian dilakukan pengujian resize. Jika terjadi kesalahan selama proses tersebut maka gambar dianggap rusak dan akan dihapus secara otomatis dari dataset.

Tahap ini bertujuan untuk:

- Menghapus file gambar yang rusak.
- Menjaga konsistensi format gambar.
- Menghindari error saat proses training.
- Meningkatkan kualitas dataset yang digunakan.



```
Train : 10
Val   : 3
Test  : 3
```

Gambar 3.2 Hasil Data Cleaning

Interpretasi:

Gambar menunjukkan hasil proses pemeriksaan dataset. Sistem melakukan validasi terhadap seluruh gambar pada folder training, validation, dan testing. Hasil pemeriksaan menunjukkan jumlah gambar yang berhasil dihapus karena mengalami kerusakan atau tidak dapat dibaca oleh sistem. Setelah proses ini selesai, seluruh gambar

yang tersisa dapat digunakan dengan aman untuk tahap preprocessing dan training model.

3.3.2 Resize Image

Setelah proses data cleaning selesai, seluruh gambar diubah ukurannya menjadi 224×224 piksel agar sesuai dengan ukuran input yang dibutuhkan oleh model EfficientNetB0. Proses resize dilakukan untuk menyeragamkan ukuran seluruh gambar sehingga model dapat menerima input dengan dimensi yang konsisten. Selain itu, ukuran 224×224 dipilih karena merupakan ukuran standar yang digunakan oleh arsitektur EfficientNetB0 pada saat proses transfer learning. Dengan ukuran yang seragam, proses pelatihan menjadi lebih efisien dan penggunaan memori dapat dikendalikan dengan lebih baik.

3.3.3 Normalisasi Data

Normalisasi dilakukan untuk mengubah nilai piksel gambar ke rentang yang lebih kecil sehingga memudahkan proses pembelajaran model. Nilai piksel yang awalnya berada pada rentang 0–255 dikonversi menjadi rentang 0–1 dengan membagi seluruh nilai piksel menggunakan angka 255. Normalisasi memiliki beberapa manfaat, yaitu:

- Mempercepat proses konvergensi model.
- Mengurangi risiko ketidakstabilan selama training.
- Membantu optimisasi parameter menjadi lebih efektif.

Dengan normalisasi, model dapat mempelajari pola citra secara lebih konsisten dibandingkan menggunakan nilai piksel asli.

3.3.4 Data Augmentation

Data augmentation merupakan teknik untuk memperbanyak variasi data pelatihan tanpa harus menambah jumlah gambar secara manual. Pada penelitian ini dilakukan beberapa teknik augmentasi seperti:

- Rotasi gambar.
- Pembalikan gambar secara horizontal.
- Zoom in dan zoom out.

- Perubahan posisi objek secara acak.

Teknik augmentasi digunakan untuk meningkatkan kemampuan generalisasi model sehingga model tidak hanya menghafal data training tetapi juga mampu mengenali gambar baru yang memiliki variasi posisi, orientasi, dan kondisi pencahayaan yang berbeda.

3.3.5 Label Encoding

Model Deep Learning tidak dapat memproses label berbentuk teks secara langsung. Oleh karena itu dilakukan proses label encoding untuk mengubah nama kelas serangga menjadi representasi numerik. Hasil label encoding kemudian disimpan dalam file metadata sehingga dapat digunakan kembali saat proses inferensi pada backend aplikasi.

```
Found 90105 images belonging to 118 classes.
Found 11212 images belonging to 118 classes.
Found 11360 images belonging to 118 classes.
```

Gambar 3.3 Jumlah Image pada Data Train, Test, dan Val

```
print(df_count["Count"].describe())
```

count	118.000000
mean	763.601695
std	1012.028125
min	28.000000
25%	210.000000
50%	421.500000
75%	867.750000
max	5038.000000
Name: Count, dtype: float64	


Gambar 3.4 Statistik Data

3.4 Exploratory Data Analysis (EDA)

Exploratory Data Analysis dilakukan untuk memahami karakteristik dataset sebelum model dilatih. Tahap ini membantu mengidentifikasi distribusi data serta variasi visual yang terdapat pada citra serangga.

3.4.1 Distribusi Jumlah Data per Kelas

Analisis distribusi data dilakukan untuk mengetahui jumlah gambar pada setiap kelas serangga. Distribusi data yang seimbang akan membantu model belajar secara lebih optimal. Sebaliknya, jika terdapat ketimpangan jumlah data antar kelas maka model berpotensi lebih sering memprediksi kelas yang memiliki jumlah data lebih banyak.



Gambar 3.5 Grafik Distribusi Data

Interpretasi:

Grafik menunjukkan distribusi jumlah gambar pada 118 kelas serangan yang digunakan dalam penelitian. Terlihat bahwa jumlah sampel pada masing-masing kelas tidak sepenuhnya seimbang (imbalanced). Beberapa kelas memiliki jumlah gambar yang jauh lebih banyak dibandingkan kelas lainnya. Ketidakseimbangan ini berpotensi menyebabkan model lebih mudah mempelajari kelas mayoritas dibandingkan kelas minoritas. Untuk mengurangi dampak tersebut, penelitian ini menerapkan teknik data augmentation selama proses preprocessing sehingga model dapat memperoleh variasi data yang lebih baik dan meningkatkan kemampuan generalisasi terhadap berbagai kelas serangan.

3.5 Pelatihan Model

3.5.1 Pembangunan Arsitektur Model

Model klasifikasi serangan dibangun menggunakan arsitektur EfficientNetB0 yang telah dilatih sebelumnya pada dataset ImageNet (pretrained model). Pendekatan yang digunakan adalah Transfer Learning, yaitu memanfaatkan bobot hasil pelatihan sebelumnya agar model dapat mempelajari karakteristik visual serangan dengan lebih cepat dan efisien dibandingkan melatih model dari awal. Pada tahap awal, seluruh layer EfficientNetB0 dibekukan (*freeze layer*) sehingga hanya bagian klasifikasi akhir (*classification head*) yang dilatih. Struktur classification head terdiri atas:

- Global Average Pooling Layer
- Batch Normalization
- Dense Layer (512 neuron)
- Dropout (0,4)
- Output Layer Softmax

Output layer memiliki 118 neuron yang mewakili 118 kelas serangan pada dataset.

Model: "functional"

Layer (type)	Output Shape	Param #	Connected to
input_layer (InputLayer)	(None, 224, 224, 3)	0	-
rescaling (Rescaling)	(None, 224, 224, 3)	0	input_layer[0][0]
normalization (Normalization)	(None, 224, 224, 3)	7	rescaling[0][0]
rescaling_1 (Rescaling)	(None, 224, 224, 3)	0	normalization[0]...
stem_conv_pad (ZeroPadding2D)	(None, 225, 225, 3)	0	rescaling_1[0][0]
stem_conv (Conv2D)	(None, 112, 112, 32)	864	stem_conv_pad[0]...
stem_bn (BatchNormalizatio...	(None, 112, 112, 32)	128	stem_conv[0][0]
stem_activation (Activation)	(None, 112, 112, 32)	0	stem_bn[0][0]
block1a_dwconv (DepthwiseConv2D)	(None, 112, 112, 32)	288	stem_activation[...
block1a_bn (BatchNormalizatio...	(None, 112, 112, 32)	128	block1a_dwconv[0]...
block1a_activation (Activation)	(None, 112, 112, 32)	0	block1a_bn[0][0]
block1a_se_squeeze (GlobalAveragePool...	(None, 32)	0	block1a_activati...
block1a_se_reshape (Reshape)	(None, 1, 1, 32)	0	block1a_se_squee...
block1a_se_reduce (Conv2D)	(None, 1, 1, 8)	264	block1a_se_resha...

Gambar 3.6 Model Summary

3.5.2 Konfigurasi Pelatihan

Model dikompilasi menggunakan konfigurasi berikut:

- Optimizer : Adam
- Learning Rate : 0.001

- Loss Function : Categorical Crossentropy
- Metrics : Accuracy, Top-5 Accuracy
- Transfer Learning : Ya

Selain accuracy, penelitian ini juga menggunakan Top-5 Accuracy untuk mengukur apakah kelas yang benar berada pada lima prediksi dengan probabilitas tertinggi.

3.5.3 Callback Training

Untuk meningkatkan kualitas pelatihan dan mencegah overfitting, digunakan beberapa callback sebagai berikut:

- Model Checkpoint
Digunakan untuk menyimpan model terbaik berdasarkan nilai validation loss.
- Early Stopping
Digunakan untuk menghentikan pelatihan secara otomatis apabila performa model tidak lagi mengalami peningkatan dalam beberapa epoch.
- Reduce Learning Rate on Plateau
Digunakan untuk menurunkan learning rate secara otomatis ketika validation loss tidak mengalami perbaikan.

3.5.4 Training Tahap Pertama

Pada tahap pertama, seluruh layer EfficientNetB0 dibekukan sehingga hanya classification head yang dilatih. Pelatihan dilakukan selama maksimum 15 epoch dengan menggunakan:

- Training Dataset
- Validation Dataset
- Class Weighting

Penggunaan Class Weighting dilakukan karena distribusi jumlah gambar pada setiap kelas tidak seimbang (*imbalanced dataset*). Teknik ini membantu model memberikan perhatian yang lebih besar pada kelas dengan jumlah data yang lebih sedikit.

```

Epoch 7: val_loss did not improve from 1.33983
1408/1408 ----- 1313s 933ms/step - accuracy: 0.6039 - loss: 1.2894 - top5_acc: 0.8555 - val_accuracy: 0.6335 - val_loss: 1.3624 - val_top5_acc: 0.874
Epoch 8/15 ----- 0s 886ms/step - accuracy: 0.6141 - loss: 1.2089 - top5_acc: 0.8630
1408/1408 ----- 1315s 935ms/step - accuracy: 0.6141 - loss: 1.2089 - top5_acc: 0.8630 - val_accuracy: 0.6335 - val_loss: 1.3624 - val_top5_acc: 0.874
Epoch 8: val_loss improved from 1.33983 to 1.31552, saving model to /content/insect_project/best_model.keras
Epoch 8: finished saving model to /content/insect_project/best_model.keras
1408/1408 ----- 1291s 917ms/step - accuracy: 0.6188 - loss: 1.2472 - top5_acc: 0.8600 - val_accuracy: 0.6441 - val_loss: 1.3155 - val_top5_acc: 0.880
Epoch 9/15 ----- 0s 888ms/step - accuracy: 0.6211 - loss: 1.1687 - top5_acc: 0.8674
1408/1408 ----- 1293s 918ms/step - accuracy: 0.6211 - loss: 1.1687 - top5_acc: 0.8674 - val_accuracy: 0.6441 - val_loss: 1.3155 - val_top5_acc: 0.880
Epoch 9: val_loss improved from 1.31552 to 1.28391, saving model to /content/insect_project/best_model.keras
Epoch 9: finished saving model to /content/insect_project/best_model.keras
1408/1408 ----- 1293s 918ms/step - accuracy: 0.6177 - loss: 1.1996 - top5_acc: 0.8646 - val_accuracy: 0.6552 - val_loss: 1.2839 - val_top5_acc: 0.882
Epoch 10/15 ----- 0s 892ms/step - accuracy: 0.6273 - loss: 1.1122 - top5_acc: 0.8738
1408/1408 ----- 1295s 922ms/step - accuracy: 0.6273 - loss: 1.1122 - top5_acc: 0.8738 - val_accuracy: 0.6552 - val_loss: 1.2839 - val_top5_acc: 0.882
Epoch 10: val_loss improved from 1.28391 to 1.25279, saving model to /content/insect_project/best_model.keras
Epoch 10: finished saving model to /content/insect_project/best_model.keras
1408/1408 ----- 1298s 922ms/step - accuracy: 0.6237 - loss: 1.1540 - top5_acc: 0.8715 - val_accuracy: 0.6611 - val_loss: 1.2528 - val_top5_acc: 0.888
Epoch 11/15 ----- 0s 906ms/step - accuracy: 0.6361 - loss: 1.0947 - top5_acc: 0.8764
1408/1408 ----- 1317s 935ms/step - accuracy: 0.6361 - loss: 1.0947 - top5_acc: 0.8764 - val_accuracy: 0.6611 - val_loss: 1.2528 - val_top5_acc: 0.888
Epoch 11: val_loss did not improve from 1.25279
1408/1408 ----- 1317s 935ms/step - accuracy: 0.6322 - loss: 1.1176 - top5_acc: 0.8762 - val_accuracy: 0.6568 - val_loss: 1.2682 - val_top5_acc: 0.887
Epoch 12/15 ----- 2:40 887ms/step - accuracy: 0.6400 - loss: 1.0587 - top5_acc: 0.8804
1227/1408 -----

```

Gambar 3.7 Epoch pada Training Tahap Pertama

Interpretasi:

Accuracy menunjukkan peningkatan performa model selama proses pelatihan. Model mampu mempelajari pola dasar dari dataset serangga dengan cukup baik menggunakan fitur yang diekstraksi oleh EfficientNetB0. Nilai loss mengalami penurunan yang menunjukkan bahwa model semakin baik dalam melakukan klasifikasi pada data pelatihan maupun validasi, meskipun pada epoch 11 nilai val_loss mengalami kenaikan. Hal ini menyebabkan data model yang diambil hanya sampai epoch 10.

3.5.5 Kendala Pelatihan

Selama proses pelatihan, GPU Google Colab yang digunakan mengalami keterbatasan penggunaan (GPU Usage Limit). Akibatnya proses training tidak dapat dilanjutkan hingga seluruh epoch selesai pada sesi pertama. Model terbaik yang telah tersimpan melalui Model Checkpoint kemudian dimuat kembali (*load model*) dan proses pelatihan dilanjutkan menggunakan sesi Google Colab yang berbeda. Oleh karena itu, grafik Accuracy dan Loss Training tidak dapat dijalankan.

3.6 Fine Tuning Model

3.6.1 Proses Fine Tuning


Setelah tahap transfer learning selesai, dilakukan proses fine tuning untuk meningkatkan kemampuan model dalam mengenali karakteristik spesifik serangga. Pada tahap ini sebagian layer EfficientNetB0 dibuka kembali (*unfreeze layer*) sehingga bobot pretrained dapat disesuaikan dengan dataset penelitian. Konfigurasi yang digunakan:

- Layer Dibekukan : 180 Layer Awal
- Layer Dilatih Ulang : Layer setelah 180
- Optimizer : Adam
- Learning Rate : 0.00001

Learning rate yang lebih kecil digunakan untuk menghindari perubahan bobot yang terlalu besar sehingga pengetahuan awal dari model pretrained tetap terjaga.

3.6.2 Training Fine Tuning


Pelatihan fine tuning dilakukan selama maksimum 10 epoch menggunakan callback yang sama seperti tahap sebelumnya.



Gambar 3.8 Grafik Fine Tuning Loss

Interpretasi:

Grafik menunjukkan peningkatan accuracy setelah dilakukan fine tuning. Hal ini menandakan bahwa model berhasil menyesuaikan bobot pretrained dengan karakteristik visual dataset serangga.



Gambar 3.9 Grafik Fine Tuning Accuracy

Interpretasi:

Nilai validation loss cenderung menurun dan stabil selama proses fine tuning. Kondisi ini menunjukkan bahwa model memiliki kemampuan generalisasi yang lebih baik terhadap data yang belum pernah dilihat sebelumnya.

3.7 Evaluasi dan Export Model

3.7.1 Evaluasi Model

Model terbaik hasil fine tuning digunakan untuk melakukan evaluasi terhadap data testing. Evaluasi dilakukan menggunakan beberapa metrik, yaitu:

- Accuracy
- Top-5 Accuracy
- Classification Report
- Confusion Matrix

```
Test Accuracy : 0.6968309879302979
Top-5 Accuracy: 0.9023767709732056
```

Gambar 3.10 Hasil Evaluasi Test Dataset

Interpretasi:

Accuracy menunjukkan persentase prediksi yang tepat terhadap keseluruhan data uji, sedangkan Top-5 Accuracy menunjukkan kemampuan model dalam menempatkan kelas yang benar ke dalam lima prediksi dengan probabilitas tertinggi. Accuracy pada evaluasi data test sebesar 0.6968, sedangkan Top-5 Accuracy sebesar 0.9023. Accuracy nya sedikit rendah dikarenakan class pada datasetnya yang tidak seimbang.

3.7.2 Classification Report


	precision	recall	f1-score	support
adristyrannus	0.5111	0.7188	0.5974	32
aleurocanthus spiniferus	0.8254	0.7536	0.7879	69
alfalfa plant bug	0.3267	0.4925	0.3929	67
alfalfa seed chalcid	0.2222	0.2105	0.2162	19
alfalfa weevil	0.3846	0.4717	0.4237	53
ampelophaga	0.4872	0.7403	0.5876	77
ant	0.8737	0.8964	0.8849	193
aphids	0.8404	0.4500	0.5861	620
apolygus lucorum	0.2949	0.5897	0.3932	39
armyworm	0.6867	0.3229	0.4393	353
asiatic rice borer	0.4771	0.4906	0.4837	106
bactrocera tsuneonis	0.4737	0.5000	0.4865	18
bee	0.9493	0.9590	0.9542	293
beet fly	0.1818	0.3636	0.2424	11
beetle	0.8693	0.5953	0.7067	257
black cutworm	0.4038	0.4884	0.4421	86
blister beetle	0.5644	0.5969	0.5802	191
bollworm	0.6667	0.4000	0.5000	5
brevipoalpus lewisi McGregor	0.6000	0.6667	0.6316	9
brown plant hopper	0.3558	0.4405	0.3936	84
butterfly	0.9172	0.9568	0.9366	139
catterpillar	0.7391	0.6476	0.6904	105
cerodonta denticornis	0.4545	0.6667	0.5405	15
ceroplastes rubens	0.6486	0.8889	0.7500	27
chayon	0.8596	0.9245	0.8909	53
chlumetia transversa	0.4615	0.5806	0.5143	31
chrysomphalus aonidum	0.6364	0.6087	0.6222	23
cicadella viridis	0.5625	0.8372	0.6729	129
cicadellidae	0.8779	0.7265	0.7950	574
corn borer	0.5604	0.5965	0.5779	171
dacus dorsalis(Hendel)	0.6226	0.7333	0.6735	45
dasineura sp	0.2692	0.4118	0.3256	51
deporaus marginatus Pascoe	0.4286	0.5714	0.4898	21
dragonfly	0.8118	1.0000	0.8961	69
earthworm	0.9091	0.8642	0.8861	81
earwig	0.8936	0.7636	0.8235	110
erythroneura apicalis	0.4000	0.7500	0.5217	8
fall armyworm	0.8392	0.9330	0.8836	179

Gambar 3.11 Classification Report

Interpretasi:

Classification Report menampilkan nilai precision, recall, dan F1-score untuk setiap kelas. Nilai yang tinggi menunjukkan bahwa model mampu mengenali kelas serangga dengan baik.

3.7.3 Confusion Matrix



Gambar 3.12 Confusion Matrix

Interpretasi:

Confusion Matrix digunakan untuk melihat distribusi prediksi benar dan salah pada setiap kelas. Kesalahan klasifikasi terjadi pada kelas yang memiliki karakteristik

visual yang mirip. Banyaknya kelas membuat gambar pada confusion matrix tidak terlalu kelihatan, tetapi dapat terlihat tidak banyak kesalahan klasifikasi yang terjadi.

3.7.4 Export Model

Setelah evaluasi selesai, model terbaik diekspor ke dalam beberapa file yang digunakan pada tahap deployment. File yang disimpan meliputi:

- `final_model.keras` : Model hasil training
- `idx_to_class.json` : Mapping indeks ke nama kelas
- `metadata.json` : Metadata model

File-file tersebut kemudian digunakan pada backend FastAPI untuk melakukan proses inferensi secara real-time.

BAB IV

IMPLEMENTASI DAN HASIL SISTEM

4.1 Implementasi Backend

Backend pada aplikasi Smart Insect Identifier dikembangkan menggunakan framework FastAPI. Backend berfungsi sebagai penghubung antara antarmuka pengguna dengan model Machine Learning yang telah dilatih sebelumnya. Arsitektur backend terdiri dari dua service utama, yaitu ML Service dan Gemini Service.

4.1.1 ML Service


ML Service bertanggung jawab untuk melakukan proses klasifikasi gambar serangga menggunakan model EfficientNetB0 yang telah dilatih. Proses yang dilakukan oleh ML Service meliputi:

- Menerima gambar dari pengguna.
- Melakukan preprocessing gambar.
- Melakukan prediksi menggunakan model hasil training.
- Menghasilkan nama kelas serangga dan nilai confidence.

Model yang digunakan pada tahap deployment adalah file:

- final_model.keras
- idx_to_class.json
- metadata.json

yang disimpan pada folder artifacts.



Gambar 4.1 Struktur Folder Backend

Interpretasi:

Backend disusun secara modular sehingga proses inferensi model dan integrasi Gemini dapat dipisahkan dengan baik. Struktur ini memudahkan pengembangan dan pemeliharaan aplikasi.

4.1.2 Gemini Service

Gemini Service digunakan untuk menghasilkan informasi tambahan mengenai serangga yang berhasil diidentifikasi oleh model. Layanan Gemini menerima hasil prediksi model sebagai petunjuk awal kemudian menghasilkan informasi berupa:

- Nama umum
- Nama ilmiah
- Deskripsi singkat
- Habitat
- Karakteristik
- Peran ekologis
- Fakta menarik


Gemini diintegrasikan menggunakan Google Gemini 2.5 Flash Lite API. Gemini Service memungkinkan sistem tidak hanya melakukan identifikasi serangga, tetapi juga memberikan wawasan tambahan yang lebih informatif kepada pengguna.

4.1.3 Endpoint API

Backend menyediakan endpoint utama:

POST /predict

Endpoint tersebut menerima file gambar yang dikirimkan dari frontend dan mengembalikan hasil klasifikasi beserta informasi AI.



Gambar 4.2 Swagger UI FastAPI

Interpretasi:

Endpoint berhasil menerima gambar, menjalankan model klasifikasi, serta menghasilkan response yang dapat digunakan oleh frontend.

4.1.3 Fallback Mechanism

Sistem menerapkan mekanisme fallback apabila layanan Gemini mengalami kegagalan akibat rate limit atau error dari server. Jika Gemini tidak dapat memberikan respons, backend tetap mengembalikan:

- Nama serangga hasil prediksi
- Confidence score

Dengan demikian, proses identifikasi tetap dapat dilakukan walaupun layanan AI sedang tidak tersedia.


4.2 Implementasi Frontend

Frontend aplikasi dikembangkan menggunakan Next.js dan Tailwind CSS. Frontend berfungsi sebagai media interaksi antara pengguna dan sistem identifikasi serangga.

4.2.1 Halaman Utama

Halaman utama menyediakan fitur upload gambar dan informasi singkat mengenai teknologi yang digunakan. Komponen utama pada halaman terdiri dari:

- Upload Area
- Preview Image
- Tombol Analisis
- Informasi Model



Gambar 4.3 Halaman Utama Aplikasi

Interpretasi:

Antarmuka dirancang sederhana dan mudah digunakan sehingga pengguna dapat langsung melakukan identifikasi hanya dengan mengunggah gambar serangga.

4.2.2 Upload dan Preview Gambar

Sebelum gambar dikirim ke backend, sistem menampilkan preview gambar yang dipilih pengguna. Fitur ini membantu pengguna memastikan gambar yang dipilih sudah benar. Preview gambar memberikan pengalaman pengguna yang lebih baik karena pengguna dapat memverifikasi gambar sebelum melakukan analisis.

4.2.3 Loading State

Ketika backend sedang melakukan proses klasifikasi dan Gemini sedang menghasilkan informasi, sistem menampilkan loading animation. Loading state memberikan umpan balik visual bahwa sistem sedang memproses data sehingga pengguna tidak menganggap aplikasi mengalami error.

4.2.4 Hasil Identifikasi

Setelah proses analisis selesai, frontend menampilkan:

- Nama serangga

- Confidence score
- Informasi AI

Informasi AI ditampilkan menggunakan React Markdown sehingga format heading dan list dapat ditampilkan dengan lebih rapi. Sistem menampilkan hasil klasifikasi beserta informasi tambahan yang dihasilkan oleh Gemini sehingga pengguna memperoleh informasi yang lebih lengkap mengenai serangan yang diidentifikasi.

4.3 Pengujian Sistem

Pengujian dilakukan untuk memastikan seluruh fitur aplikasi berjalan sesuai kebutuhan.

4.3.1 Pengujian Fungsional

- Upload gambar : Berhasil
- Preview gambar : Berhasil
- Prediksi serangan : Berhasil
- Menampilkan confidence score : Berhasil
- Menampilkan AI Insights : Berhasil
- Fallback Gemini : Berhasil

Berdasarkan hasil pengujian, seluruh fitur utama aplikasi dapat berjalan sesuai dengan kebutuhan sistem.

4.3.2 Pengujian End-to-End

Pengujian dilakukan dengan mengunggah beberapa gambar serangan dari dataset testing ke dalam aplikasi.

Tahapan yang dilakukan:

1. Pengguna mengunggah gambar.
2. Frontend mengirim gambar ke backend.
3. Backend melakukan inferensi model.
4. Backend memanggil Gemini API.
5. Hasil dikembalikan ke frontend.
6. Frontend menampilkan hasil identifikasi.



Gambar 4.4 Pengujian End-to-End

Interpretasi:

Seluruh komponen sistem berhasil terintegrasi dengan baik mulai dari frontend, backend, model Machine Learning, hingga layanan Gemini AI.

4.4 Pengujian Sistem

Gemini AI digunakan untuk menghasilkan informasi tambahan mengenai serangga yang berhasil diprediksi oleh model. Informasi yang diberikan meliputi:

- Nama umum
- Nama ilmiah
- Habitat
- Karakteristik
- Peran ekologis
- Fakta menarik



Gambar 4.5 Pengujian Sistem

Interpretasi:

Gemini mampu menghasilkan informasi yang mudah dipahami dan relevan dengan hasil prediksi model. Informasi tersebut dapat membantu pengguna memahami karakteristik serangga tanpa harus mencari referensi tambahan secara manual. Selain itu, penggunaan prompt yang terstruktur membuat output Gemini menjadi lebih konsisten dan lebih mudah ditampilkan pada antarmuka aplikasi menggunakan format markdown.

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan hasil penelitian dan pengembangan yang telah dilakukan, dapat diperoleh beberapa kesimpulan sebagai berikut:

1. Model EfficientNetB0 berhasil digunakan untuk melakukan klasifikasi citra serangga pada dataset yang terdiri dari 118 kelas berbeda.
2. Pendekatan Transfer Learning dan Fine Tuning mampu meningkatkan kemampuan model dalam mengenali karakteristik visual serangga dengan lebih baik dibandingkan pelatihan dari awal.
3. Penggunaan Class Weighting membantu mengatasi permasalahan ketidakseimbangan jumlah data pada masing-masing kelas sehingga model dapat belajar secara lebih merata.
4. Backend yang dibangun menggunakan FastAPI berhasil melakukan proses inferensi model dan integrasi dengan Gemini AI melalui REST API.
5. Frontend yang dibangun menggunakan Next.js dan Tailwind CSS berhasil menyediakan antarmuka yang interaktif untuk proses upload gambar, analisis, dan visualisasi hasil prediksi.
6. Integrasi Gemini AI mampu memberikan informasi tambahan yang lebih informatif berupa nama umum, nama ilmiah, habitat, karakteristik, peran ekologis, dan fakta menarik mengenai serangga yang berhasil diidentifikasi.
7. Sistem tetap dapat memberikan hasil prediksi meskipun layanan Gemini mengalami gangguan melalui mekanisme fallback yang telah diterapkan pada backend.

Secara keseluruhan, aplikasi Smart Insect Identifier berhasil memenuhi tujuan penelitian yaitu melakukan identifikasi serangga secara otomatis sekaligus memberikan wawasan tambahan berbasis Large Language Model.

5.1 Saran

Beberapa saran yang dapat dilakukan untuk pengembangan sistem pada penelitian selanjutnya adalah sebagai berikut :

1. Menambahkan jumlah data pelatihan agar model memiliki kemampuan generalisasi yang lebih baik terhadap variasi gambar serangga di dunia nyata.
2. Menggunakan teknik penanganan data imbalance yang lebih kompleks seperti oversampling, undersampling, atau focal loss untuk meningkatkan performa pada kelas minoritas.
3. Mengimplementasikan arsitektur model yang lebih modern seperti EfficientNetV2, ConvNeXt, atau Vision Transformer untuk memperoleh akurasi yang lebih tinggi.
4. Menambahkan fitur riwayat prediksi sehingga pengguna dapat melihat kembali hasil identifikasi yang telah dilakukan sebelumnya.
5. Mengembangkan sistem menjadi aplikasi berbasis cloud sehingga dapat diakses secara online tanpa perlu menjalankan backend secara lokal.
6. Mengintegrasikan fitur Google Search Grounding pada Gemini agar informasi yang dihasilkan lebih aktual dan memiliki referensi yang lebih kuat.
7. Menambahkan dukungan multi-bahasa sehingga aplikasi dapat digunakan oleh pengguna dari berbagai negara.
8. Menambahkan fitur rekomendasi penanganan hama pertanian berdasarkan hasil identifikasi serangga yang diperoleh dari model.
9. Secara keseluruhan, aplikasi Smart Insect Identifier berhasil memenuhi tujuan penelitian yaitu melakukan identifikasi serangga secara otomatis sekaligus memberikan wawasan tambahan berbasis Large Language Model.